Mathématiques

Première & Terminale

Spécialité mathématiques
Mathématiques expertes

Philibert Pappens

Cours et exercices

Préface

« La dernière démarche de la raison est de reconnaître qu'il y a une infinité de choses qui la surpassent. »

Blaise Pascal, *Pensées* [89]

Pour Pascal, la raison s'achève en reconnaissant tout ce qui la dépasse. Les mathématiques en donnent une mesure concrète : ce que l'on apprend en deux années de lycée a demandé plus de deux millénaires de travail. Le nombre réel, la limite ou la probabilité ont mis des siècles à être conçus, formulés, puis simplifiés, chaque génération reprenant le travail des précédentes. Ce livre voudrait rendre visible ce poids du passé : chaque résultat y est démontré à partir de ceux qui le précèdent, et des repères historiques, avec les références aux textes originaux réunies dans la bibliographie, indiquent d'où il vient.

Cet ouvrage couvre l'ensemble des programmes de mathématiques du lycée (spécialité de Première, spécialité de Terminale et option mathématiques expertes) avec le niveau d'exigence des classes préparatoires. Il s'adresse aux élèves qui veulent comprendre pourquoi les résultats du cours sont vrais, et pas seulement savoir s'en servir. Je l'ai d'abord écrit pour mes neveux et nièces, pour le jour où ils en auront l'usage.

Le parti pris est celui des classes préparatoires : chaque notion est définie précisément, chaque énoncé est écrit avec ses quantificateurs, et chaque résultat est démontré ; les rares résultats admis sont signalés comme tels. C'est sous cette forme, rigoureuse et formalisée, que j'ai découvert les mathématiques au lycée, et c'est ce qui me les a fait aimer. J'ai voulu en garder ici l'exigence.

Le livre n'est pas organisé par années, mais par domaines : logique, analyse, algèbre, géométrie, probabilités. Chaque théorie est ainsi exposée d'un seul tenant, et les structures communes apparaissent : groupes, anneaux, corps et espaces vectoriels servent de langage à l'arithmétique, aux nombres complexes, aux matrices et à la géométrie. De nombreux exemples viennent de la physique, de la biologie, de l'économie ou de l'informatique, et le dernier chapitre montre comment ces outils fondent l'intelligence artificielle actuelle.

Le premier chapitre fixe le langage utilisé dans tout le livre. Le guide de lecture qui suit indique à quel programme se rattache chaque partie. Les passages hors programme sont signalés et peuvent être omis en première lecture. Chaque partie se termine par un encadré « À retenir », puis par des exercices classés de ⋆ à ⋆⋆⋆ ; les plus difficiles sont du niveau de la première année de classe préparatoire. Chaque chapitre se clôt par des problèmes de synthèse, plus longs, qui mêlent plusieurs parties du livre. Les corrigés sont rassemblés en fin d'ouvrage, précédés d'indications pour les exercices ⋆⋆⋆.

Philibert Pappens

Table des matières

Préface **iii**

Guide de lecture **xi**

Notations **xv**

1 Logique et ensembles **1**
I Ensembles et applications 1
I.1 Ensembles et parties 1
I.2 Applications 2
Exercices 4
II Logique et raisonnement 5
II.1 Propositions et connecteurs 5
II.2 Quantificateurs 6
II.3 Les types de raisonnement 7
Exercices 8
III Algorithmique et programmation 9
III.1 Variables, instructions, fonctions 9
III.2 Les listes 10
III.3 Terminaison et correction — hors programme 11
Exercices 13
Problèmes 14

2 Analyse **17**
I La droite des réels 17

Exercice 2.7 (⋆⋆⋆ Les nombres $a + b\sqrt{2}$)**.** Soit $G = \{a + b\sqrt{2} \mid a, b \in \mathbf{Z}\}$.

(a) Montrer que G est stable par addition, par passage à l'opposé et par multiplication.

(b) Soit $u = \sqrt{2} - 1$. Montrer que $u \in G$, que $0 < u < 1$, et que pour tout $\varepsilon > 0$ il existe un élément g de G tel que $0 < g < \varepsilon$.

(c) En déduire que tout intervalle $]x, y[$ (avec $x < y$) contient un élément de G.

II. Suites numériques

Les suites sont nées de problèmes de calcul bien avant d'être définies. Archimède (IIIe siècle avant notre ère) encadre la longueur du cercle par les périmètres de polygones réguliers inscrits et circonscrits, dont il double le nombre de côtés à chaque étape : il construit deux suites qui convergent vers 2π [51]. Au Ier siècle, Héron d'Alexandrie décrit un procédé itératif d'extraction des racines carrées, que nous étudierons [51]. En 1202, Léonard de Pise introduit dans son *Liber abaci* la suite qui porte aujourd'hui son surnom, Fibonacci, pour décrire la croissance d'une population de lapins [69].

Il faut attendre le XIXe siècle pour qu'une suite devienne un objet mathématique à part entière : Cauchy, dans son *Cours d'analyse* de 1821 [14], définit la convergence et en fait le point de départ de l'analyse. C'est le point de vue adopté ici.

II.1 Raisonnement par récurrence

Beaucoup de propriétés des suites portent sur tous les entiers naturels. Pour les établir, on dispose d'un outil fondamental.

Théorème II.1 (Principe de récurrence)**.** Soit $n_0 \in \mathbf{N}$ et, pour tout entier $n \geq n_0$, soit $\mathcal{P}(n)$ une propriété dépendant de n. On suppose que :

— *(initialisation)* $\mathcal{P}(n_0)$ est vraie ;

— *(hérédité)* pour tout entier $n \geq n_0$, si $\mathcal{P}(n)$ est vraie, alors $\mathcal{P}(n+1)$ est vraie.

Alors $\mathcal{P}(n)$ est vraie pour tout entier $n \geq n_0$.

Preuve. Hors programme. On admet la propriété suivante de $\mathbf{N}$: toute partie non vide de $\mathbf{N}$ admet un plus petit élément.

Par l'absurde, supposons que l'ensemble $E = \{n \geq n_0 \mid \mathcal{P}(n) \text{ est fausse}\}$ soit non vide. Il admet un plus petit élément m. Par initialisation, $m \neq n_0$, donc $m - 1 \geq n_0$. Par minimalité de m, $m - 1 \notin E$, donc $\mathcal{P}(m-1)$ est vraie, puis $\mathcal{P}(m)$ est vraie par hérédité : c'est absurde puisque $m \in E$. Donc E est vide. ■

Remarque. Une démonstration par récurrence se rédige en trois étapes : initialisation, hérédité, conclusion. Dans l'hérédité, on fixe $n \geq n_0$, on suppose $\mathcal{P}(n)$ vraie (*hypothèse de récurrence*) et on démontre $\mathcal{P}(n+1)$.

II.2 Définitions

Définition II.1 (Suite numérique)**.** Une *suite réelle* est une application u de $\mathbf{N}$ dans $\mathbf{R}$. On note u_n l'image de l'entier n, appelée *terme d'indice* n, et l'on note la suite u, $(u_n)_{n\in\mathbf{N}}$ ou simplement (u_n). L'ensemble des suites réelles est noté $\mathbf{R}^{\mathbf{N}}$.

Remarque. On considère aussi des suites définies à partir d'un rang n_0, notées $(u_n)_{n\geq n_0}$. Une propriété est vraie *à partir d'un certain rang* s'il existe $N \in \mathbf{N}$ tel que la suite $(u_n)_{n\geq N}$ la vérifie.

Une suite peut être donnée par une formule explicite, comme $u_n = \frac{1}{n+1}$, ou *par récurrence* : on se donne u_0 et une fonction f, et l'on pose $u_{n+1} = f(u_n)$ pour tout $n \in \mathbf{N}$. Le principe de récurrence (théorème II.1) garantit que tous les termes sont alors déterminés, pourvu que $f(u_n)$ soit défini à chaque étape.

Exemple II.1 (Suite arithmétique)**.** Soient $a, u_0 \in \mathbf{R}$. La *suite arithmétique* de raison a et de premier terme u_0 est définie par $u_{n+1} = u_n + a$ pour tout $n \in \mathbf{N}$. Par exemple, la suite de raison 2 et de premier terme 0 (resp. 1) est la suite des entiers pairs (resp. impairs).

Propriété II.1 (Suite arithmétique)**.** Soient $a, u_0 \in \mathbf{R}$ et u la suite arithmétique de raison a et de premier terme u_0. Pour tout $n \in \mathbf{N}$, $u_n = u_0 + na$. Réciproquement, une suite de cette forme est arithmétique, de raison a.

Preuve. C'est notre première démonstration par récurrence ; on en détaille les trois étapes. Pour tout $n \in \mathbf{N}$, notons $\mathcal{P}(n)$: « $u_n = u_0 + na$ ».

Initialisation. $u_0 = u_0 + 0 \cdot a$, donc $\mathcal{P}(0)$ est vraie.

Hérédité. Soit $n \in \mathbf{N}$ tel que $\mathcal{P}(n)$ soit vraie. Alors $u_{n+1} = u_n + a = (u_0 + na) + a = u_0 + (n+1)a$: $\mathcal{P}(n+1)$ est vraie.

Conclusion. Par récurrence, $u_n = u_0 + na$ pour tout $n \in \mathbf{N}$.

La réciproque est immédiate : si $u_n = u_0 + na$ pour tout n, alors $u_{n+1} - u_n = a$. ■

Exemple II.2 (Suite géométrique)**.** Soient $q, u_0 \in \mathbf{R}$. La *suite géométrique* de raison q et de premier terme u_0 est définie par $u_{n+1} = q\,u_n$ pour tout $n \in \mathbf{N}$. Par exemple, la suite des puissances de 2 est la suite géométrique de premier terme 1 et de raison 2.

Propriété II.2 (Suite géométrique)**.** Soient $q, u_0 \in \mathbf{R}$ et u la suite géométrique de raison q et de premier terme u_0. Pour tout $n \in \mathbf{N}$, $u_n = u_0 q^n$.

Preuve. Pour tout $n \in \mathbf{N}$, notons $\mathcal{P}(n)$: « $u_n = u_0 q^n$ ». La propriété $\mathcal{P}(0)$ est vraie car $q^0 = 1$. Soit $n \in \mathbf{N}$ tel que $\mathcal{P}(n)$ soit vraie ; alors $u_{n+1} = q\,u_n = q\,u_0 q^n = u_0 q^{n+1}$, donc $\mathcal{P}(n+1)$ est vraie. Par récurrence, $\mathcal{P}(n)$ est vraie pour tout $n \in \mathbf{N}$. ■

Proposition II.1 (Sommes de termes consécutifs)**.**

(a) Pour tout $n \in \mathbf{N}$,

$$1 + 2 + \cdots + n = \sum_{k=0}^{n} k = \frac{n(n+1)}{2}.$$

(b) Soit $q \in \mathbf{R} \setminus \{1\}$. Pour tout $n \in \mathbf{N}$,

$$1 + q + \cdots + q^n = \sum_{k=0}^{n} q^k = \frac{1 - q^{n+1}}{1 - q}.$$

Preuve. Soit $n \in \mathbf{N}$.

(a) Notons $S = \sum_{k=0}^{n} k$. En sommant dans l'ordre inverse (changement d'indice $k \mapsto n - k$), $S = \sum_{k=0}^{n} (n - k)$. En ajoutant les deux écritures, $2S = \sum_{k=0}^{n} n = n(n+1)$.

(b) Notons $S = \sum_{k=0}^{n} q^k$. Alors $qS = \sum_{k=1}^{n+1} q^k$, donc par télescopage $S - qS = 1 - q^{n+1}$. Comme $q \neq 1$, on divise par $1 - q$. ■

Remarque. Pour $q = 1$, la somme vaut $n + 1$. On en déduit les sommes de termes consécutifs : si u est arithmétique de raison a, $\sum_{k=0}^{n} u_k = (n+1)u_0 + a\,\frac{n(n+1)}{2} = (n+1)\,\frac{u_0 + u_n}{2}$; si u est géométrique de raison $q \neq 1$, $\sum_{k=0}^{n} u_k = u_0\,\frac{1-q^{n+1}}{1-q}$.

Définition II.2 (Monotonie d'une suite)**.** Soit u une suite réelle. On dit que u est :

- *croissante* si, pour tous $n, m \in \mathbf{N}$ tels que $n \leq m$, $u_n \leq u_m$;
- *strictement croissante* si, pour tous $n, m \in \mathbf{N}$ tels que $n < m$, $u_n < u_m$;

— *décroissante* (resp. *strictement décroissante*) si la suite $(-u_n)$ est croissante (resp. strictement croissante) ;
— *monotone* si elle est croissante ou décroissante, *strictement monotone* si elle est strictement croissante ou strictement décroissante.

Proposition II.2 (Monotonie)**.** Soit u une suite réelle.

— u est croissante si et seulement si $u_n \leq u_{n+1}$ pour tout $n \in \mathbf{N}$; strictement croissante si et seulement si $u_n < u_{n+1}$ pour tout $n \in \mathbf{N}$.
— Si $u_n > 0$ pour tout $n \in \mathbf{N}$, u est croissante si et seulement si $\frac{u_{n+1}}{u_n} \geq 1$ pour tout $n \in \mathbf{N}$; strictement croissante si et seulement si $\frac{u_{n+1}}{u_n} > 1$ pour tout $n \in \mathbf{N}$.

On a les mêmes énoncés pour la décroissance, en renversant les inégalités.

Preuve. Le sens direct est la définition appliquée à $m = n+1$. Réciproquement, supposons $u_k \leq u_{k+1}$ pour tout $k \in \mathbf{N}$, et fixons $n \in \mathbf{N}$. Par récurrence sur $m \geq n$, $u_n \leq u_m$: c'est vrai pour $m = n$, et si $u_n \leq u_m$, alors $u_n \leq u_m \leq u_{m+1}$. Le cas strict est identique. Lorsque $u_n > 0$, l'inégalité $u_n \leq u_{n+1}$ équivaut à $\frac{u_{n+1}}{u_n} \geq 1$. ■

Définition II.3 (Suite majorée, minorée, bornée)**.** Soit u une suite réelle. On dit que u est :

— *majorée* s'il existe $M \in \mathbf{R}$ tel que, pour tout $n \in \mathbf{N}$, $u_n \leq M$;
— *minorée* s'il existe $m \in \mathbf{R}$ tel que, pour tout $n \in \mathbf{N}$, $u_n \geq m$;
— *bornée* si elle est majorée et minorée, c'est-à-dire s'il existe $M \in \mathbf{R}$ tel que, pour tout $n \in \mathbf{N}$, $|u_n| \leq M$.

II.3 Limite d'une suite

Définition II.4 (Limite d'une suite)**.** Soient u une suite réelle et $\ell \in \mathbf{R}$.

— On dit que u *converge* vers ℓ, ou *tend* vers ℓ, et l'on note $\lim\limits_{n\to+\infty} u_n = \ell$ ou $u_n \to \ell$, si

$$\forall \varepsilon > 0,\ \exists n_0 \in \mathbf{N},\ \forall n \geq n_0,\ |u_n - \ell| \leq \varepsilon.$$

Une suite qui converge vers un réel est dite *convergente* ; sinon, elle est dite *divergente*.
— On dit que u tend vers $+\infty$, et l'on note $\lim\limits_{n\to+\infty} u_n = +\infty$, si

$$\forall A \in \mathbf{R},\ \exists n_0 \in \mathbf{N},\ \forall n \geq n_0,\ u_n \geq A.$$

(a) Justifier que tan est définie, impaire et dérivable sur I, et que $\tan' = 1 + \tan^2 = \frac{1}{\cos^2}$. Déterminer ses limites aux bornes de I.

(b) Montrer que tan est une bijection de I sur $\mathbf{R}$. On note $\arctan\colon \mathbf{R} \to I$ sa réciproque. En admettant que arctan est dérivable, montrer que $\arctan'(x) = \frac{1}{1+x^2}$ pour tout réel x.

(c) Montrer que, pour tout $x > 0$, $\arctan x + \arctan \frac{1}{x} = \frac{\pi}{2}$.

Exercice 2.25 (⋆⋆ L'algorithme de Briggs)**.** Pour calculer ses tables de logarithmes (1617–1624), Henry Briggs extrait successivement des racines carrées : $\sqrt{x}$, $\sqrt{\sqrt{x}}$, etc. Pour $x > 0$ et $n \in \mathbf{N}$, on note $r_n(x) = x^{1/2^n} = \exp\left(\frac{\ln x}{2^n}\right)$, obtenu par n extractions successives de racines carrées.

(a) Montrer que, pour tout $h \geq 0$, $h \leq \mathrm{e}^h - 1 \leq h\,\mathrm{e}^h$.

(b) En déduire que, pour tout $x \geq 1$ et tout $n \in \mathbf{N}$,

$$\ln x \leq 2^n\big(r_n(x) - 1\big) \leq r_n(x)\,\ln x,$$

puis que $2^n\big(r_n(x) - 1\big) \to \ln x$.

(c) Pour $x = 10$ et $n = 20$, on trouve $2^{20}\big(r_{20}(10) - 1\big) \approx 2{,}302\,588$. Quelle précision sur $\ln 10$ l'encadrement garantit-il ?

Exercice 2.26 (⋆⋆⋆ Un produit infini)**.**

(a) Montrer que, pour tout $x \geq 0$, $x - \frac{x^2}{2} \leq \ln(1+x) \leq x$.

(b) Déterminer la limite de $P_n = \displaystyle\prod_{k=1}^{n}\left(1 + \frac{k}{n^2}\right)$ lorsque $n \to +\infty$.

V. Dérivation

La dérivation formalise l'idée de *taux de variation instantané* : la pente d'une courbe en un point, la vitesse d'un mobile à un instant, le coût marginal en économie. Le calcul différentiel, élaboré à la fin du XVIIe siècle par Newton et Leibniz [68, 82] à partir de notions intuitives d'infiniment petit, ne fut rigoureusement fondé qu'au XIXe siècle avec la notion de limite [14]. Nous distinguons le point de vue *local* (le nombre dérivé en un point) du point de vue *global* (la fonction dérivée), avant d'étudier les opérations, la composition, et le lien fondamental entre dérivée et variations.

V.1 Nombre dérivé et tangente

Définition V.1 (Taux de variation)**.** Soit f une fonction définie sur un intervalle I et $a \in I$. Pour tout réel $h \neq 0$ tel que $a + h \in I$, le *taux de variation* (ou taux d'accroissement) de f entre a et $a + h$ est

$$\tau_a(h) = \frac{f(a+h) - f(a)}{h}.$$

Géométriquement, $\tau_a(h)$ est la pente de la sécante à la courbe représentative de f passant par les points d'abscisses a et $a + h$.

Définition V.2 (Nombre dérivé)**.** Soit f une fonction définie sur un intervalle I et $a \in I$. On dit que f est *dérivable en a* si le taux de variation admet une limite finie quand h tend vers 0. Cette limite est alors appelée *nombre dérivé* de f en a et notée $f'(a)$:

$$f'(a) = \lim_{h \to 0} \frac{f(a+h) - f(a)}{h} = \lim_{x \to a} \frac{f(x) - f(a)}{x - a}.$$

Remarque. Les deux écritures sont équivalentes par le changement de variable $x = a + h$. La seconde met en évidence que $f'(a)$ ne dépend que du comportement de f au voisinage de a.

Proposition V.1 (Dérivabilité entraîne continuité)**.** Soit f une fonction définie sur un intervalle I et $a \in I$. Si f est dérivable en a, alors f est continue en a.

Preuve. Pour tout $x \in I$ avec $x \neq a$, on écrit

$$f(x) - f(a) = \frac{f(x) - f(a)}{x - a}\,(x - a).$$

Quand $x \to a$, le premier facteur tend vers $f'(a)$ (limite finie, par hypothèse) et le second vers 0 ; par produit des limites, $f(x) - f(a) \to 0$, c'est-à-dire $f(x) \to f(a)$. La fonction f est donc continue en a. ∎

Remarque. La réciproque est fausse : une fonction peut être continue en a sans y être dérivable, comme le montrent les exemples de la valeur absolue et de la racine carrée ci-dessous.

Définition V.3 (Tangente)**.** Soit f une fonction dérivable en a. La *tangente* à la courbe représentative de f au point d'abscisse a est la droite passant par le point $(a, f(a))$ et de pente $f'(a)$.

Proposition V.2 (Équation de la tangente)**.** Soit f une fonction dérivable en a. La tangente à la courbe représentative de f au point d'abscisse a a pour équation

$$y = f(a) + f'(a)(x - a).$$

Preuve. La sécante passant par les points d'abscisses a et $a + h$ a pour pente $\tau_a(h)$ et passe par $(a, f(a))$; son équation est $y = f(a)+\tau_a(h)(x-a)$. Lorsque $h \to 0$, la pente $\tau_a(h)$ tend vers $f'(a)$: la tangente est la position limite de ces sécantes, d'où son équation $y = f(a) + f'(a)(x - a)$. ■

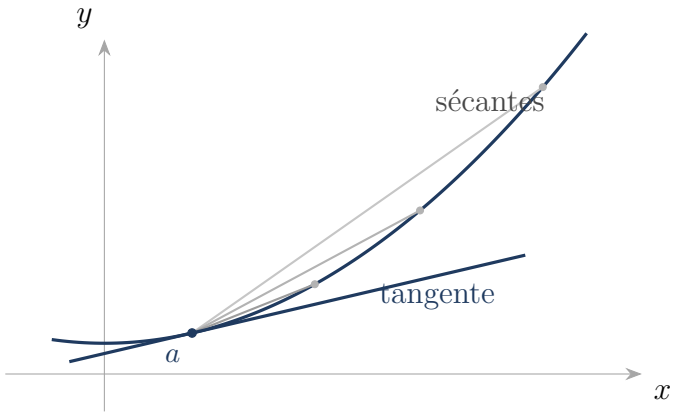


Figure 2.23 Lorsque le second point se rapproche de a, les sécantes tendent vers la tangente.

Proposition V.3 (Approximation affine locale)**.** Soit f une fonction dérivable en a. Alors, au voisinage de 0,

$$f(a + h) = f(a) + f'(a)\,h + h\,\varepsilon(h), \qquad \text{où } \lim_{h\to 0} \varepsilon(h) = 0.$$

Autrement dit, $f(a + h) \approx f(a) + f'(a)\,h$: la tangente est la meilleure approximation affine de f au voisinage de a.

Preuve. Posons $\varepsilon(h) = \tau_a(h) - f'(a)$ pour $h \neq 0$, et $\varepsilon(0) = 0$. Par définition du nombre dérivé, $\lim_{h\to 0} \varepsilon(h) = 0$. Pour tout $h \neq 0$,

$$f(a + h) - f(a) = \tau_a(h)\,h = \Big(f'(a) + \varepsilon(h)\Big)h = f'(a)\,h + h\,\varepsilon(h),$$

et cette égalité reste vraie pour $h = 0$. D'où le résultat. ■

Proposition I.2 (Forme canonique)**.** Posons $\Delta = b^2 - 4ac$, appelé *discriminant* du trinôme, $\alpha = -\dfrac{b}{2a}$ et $\beta = -\dfrac{\Delta}{4a}$. Pour tout $x \in \mathbf{R}$,

$$ax^2 + bx + c = a\left[\left(x + \frac{b}{2a}\right)^2 - \frac{\Delta}{4a^2}\right] = a(x - \alpha)^2 + \beta.$$

En particulier, $\beta = f(\alpha)$.

Preuve. Soit $x \in \mathbf{R}$. Comme $a \neq 0$, on factorise par a, puis on reconnaît dans $x^2 + \frac{b}{a}x$ le début du carré $\left(x + \frac{b}{2a}\right)^2 = x^2 + \frac{b}{a}x + \frac{b^2}{4a^2}$:

$$ax^2+bx+c = a\left[x^2+\frac{b}{a}x+\frac{c}{a}\right] = a\left[\left(x+\frac{b}{2a}\right)^2-\frac{b^2}{4a^2}+\frac{4ac}{4a^2}\right] = a\left[\left(x+\frac{b}{2a}\right)^2-\frac{\Delta}{4a^2}\right].$$

En développant le crochet, on obtient $a(x-\alpha)^2 - \frac{\Delta}{4a} = a(x-\alpha)^2 + \beta$. Enfin $f(\alpha) = a \times 0 + \beta = \beta$. ∎

Exemple I.1 (La figure d'al-Khwārizmī)**.** Le premier exemple du traité d'al-Khwārizmī se lit, en notations modernes, $x^2 + 10x = 39$, avec $x > 0$. On dessine un carré de côté x et l'on accole à deux de ses côtés des rectangles de dimensions $5 \times x$: l'aire totale vaut $x^2 + 10x = 39$. Il manque, pour obtenir un grand carré de côté $x + 5$, un petit carré de côté 5, d'aire 25 (fig. 3.1). Le grand carré a donc pour aire $39 + 25 = 64$, son côté vaut 8, et $x = 3$. C'est exactement le calcul $x^2 + 10x - 39 = (x + 5)^2 - 64$ de la forme canonique. La figure ne voit pas la seconde solution, $x = -13$, qu'un mathématicien du IXe siècle n'aurait de toute façon pas acceptée : une longueur est positive.

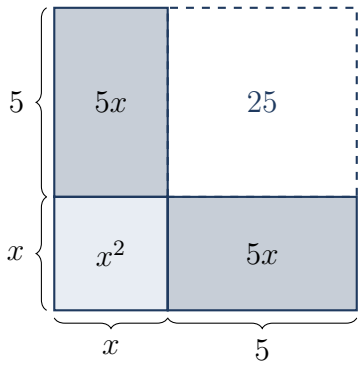


Figure 3.1 La complétion du carré d'al-Khwārizmī pour $x^2 + 10x = 39$. Le carré de côté x et les deux rectangles $5 \times x$ ont une aire totale de 39 ; en ajoutant le carré de côté 5 (en pointillés), on obtient un carré de côté $x + 5$ et d'aire $39 + 25 = 64$, donc $x + 5 = 8$.

Proposition I.3 (Variations et courbe)**.** Soit $f : x \mapsto ax^2 + bx + c$, et α, β comme dans la proposition I.2.

(a) Si $a > 0$, f est strictement décroissante sur $]-\infty, \alpha]$, strictement croissante sur $[\alpha, +\infty[$, et admet en α un minimum égal à β. Si $a < 0$, c'est l'inverse, et β est un maximum.

(b) Pour tout $h \in \mathbf{R}$, $f(\alpha+h) = f(\alpha-h)$: la courbe de f, appelée *parabole*, est symétrique par rapport à la droite d'équation $x = \alpha$. Le point (α, β) est son *sommet*.

Preuve. (a) Supposons $a > 0$. Pour tout $x \in \mathbf{R}$, $f(x) - \beta = a(x-\alpha)^2 \geq 0$, avec égalité si et seulement si $x = \alpha$: β est le minimum de f. Soient $x < y \leq \alpha$; alors $x - \alpha < y - \alpha \leq 0$, donc $(x-\alpha)^2 > (y-\alpha)^2$ par stricte décroissance de la fonction carré sur $\mathbf{R}_-$, et $f(x) > f(y)$. On procède de même sur $[\alpha, +\infty[$, où la fonction carré est strictement croissante. Le cas $a < 0$ s'en déduit en changeant f en $-f$. (b) $f(\alpha + h) = ah^2 + \beta = a(-h)^2 + \beta = f(\alpha - h)$. ■

Remarque. Ces résultats n'utilisent pas la dérivation, mais ils la retrouvent : $f'(x) = 2ax + b$ s'annule en $\alpha = -\frac{b}{2a}$, en changeant de signe (théorème V.5 du chapitre 2).

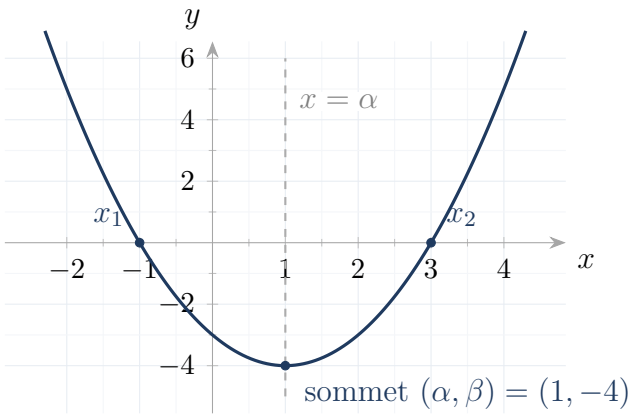


Figure 3.2 La parabole d'équation $y = x^2 - 2x - 3 = (x-1)^2 - 4$. Elle est symétrique par rapport à la droite $x = 1$; son sommet est le point le plus bas, et ses racines -1 et 3 sont symétriques par rapport à l'axe : leur moyenne est $\alpha = -\frac{b}{2a}$.

I.2 Racines et factorisation

Théorème I.1 (Équation du second degré)**.** Considérons l'équation $ax^2 + bx + c = 0$, d'inconnue $x \in \mathbf{R}$, et son discriminant $\Delta = b^2 - 4ac$.

(a) Si $\Delta < 0$, elle n'a aucune solution réelle.

(b) Si $\Delta = 0$, elle a une unique solution, $x_0 = -\dfrac{b}{2a}$.

Chapitre 5

Probabilités et statistique

I. Espaces probabilisés

En 1654, le chevalier de Méré, joueur assidu, soumet à Pascal des questions de jeux de dés qui le troublent. La correspondance qui s'ensuit entre Pascal et Fermat [33] fonde le calcul des probabilités : pour la première fois, on raisonne avec rigueur sur ce qui *n'est pas certain*. Huygens en tire le premier traité (1657) [56], Jacques Bernoulli la loi des grands nombres (1713) [3], Laplace une théorie générale (1812) [65] ; pour cette histoire, voir [47, 109]. Il faut pourtant attendre 1933 pour que Kolmogorov donne au sujet ses fondations définitives [62, 105] : une probabilité est une fonction qui attribue un poids aux événements en respectant quelques axiomes, et toute la théorie s'en déduit. C'est ce point de vue que nous adoptons. Un modèle probabiliste ne dit pas ce qui *va* se passer ; il décrit précisément notre ignorance, et permet d'en tirer des conséquences certaines.

Les outils de dénombrement utilisés ici sont établis dans la partie II du chapitre 3.

I.1 Expérience aléatoire, univers, événements

Une *expérience aléatoire* est une expérience dont on connaît l'ensemble des résultats possibles, mais dont on ne peut prévoir le résultat : lancer un dé, tirer une carte, interroger un électeur au hasard, mesurer la durée de vie d'un atome.

Définition I.1 (Univers, issue, événement)**.** On modélise une expérience aléatoire par un ensemble non vide Ω, appelé *univers*, dont les éléments $\omega \in \Omega$ sont les *issues* (ou résultats) possibles. Jusqu'au paragraphe I.6, l'univers est supposé *fini*.

Un *événement* est une partie A de Ω ; on dit que A est *réalisé* si l'issue ω de l'expérience appartient à A. L'ensemble des événements est donc $\mathcal{P}(\Omega)$.

Le langage des ensembles se traduit en langage des événements :

Notation	Ensembles	Probabilités
Ω	ensemble entier	événement certain
$\varnothing$	ensemble vide	événement impossible
$\{\omega\}$	singleton	événement élémentaire
$\overline{A} = \Omega \setminus A$	complémentaire de A	événement contraire de A
$A \cap B$	intersection	A et B
$A \cup B$	réunion	A ou B
$A \cap B = \varnothing$	A et B disjoints	A et B incompatibles
$A \subset B$	A inclus dans B	A implique B

Définition I.2 (Système complet d'événements)**.** Soit $n \in \mathbf{N}^*$. Des événements $A_1, \ldots, A_n$ forment un *système complet d'événements* s'ils sont deux à deux incompatibles et si leur réunion est Ω : à l'issue de l'expérience, un et un seul d'entre eux est réalisé.

Exemple I.1 (Deux dés)**.** On lance deux dés, un rouge et un bleu. On choisit $\Omega = [\![1, 6]\!]^2$: l'issue (i, j) signifie que le dé rouge donne i et le dé bleu j, donc $\operatorname{Card} \Omega = 36$. L'événement « la somme vaut 7 » est

$$\{(1, 6), (2, 5), (3, 4), (4, 3), (5, 2), (6, 1)\}.$$

Les événements « la somme vaut s », pour $s \in [\![2, 12]\!]$, forment un système complet d'événements.

I.2 Probabilité sur un univers fini

Définition I.3 (Probabilité, espace probabilisé fini)**.** Soit Ω un univers fini. Une *probabilité* sur Ω est une application $\mathbf{P} \colon \mathcal{P}(\Omega) \to [0, 1]$ telle que :

- $\mathbf{P}(\Omega) = 1$;
- *(additivité)* pour tous événements A, B incompatibles, $\mathbf{P}(A \cup B) = \mathbf{P}(A) + \mathbf{P}(B)$.

Le couple $(\Omega, \mathbf{P})$ est appelé *espace probabilisé fini*.

(a) Montrer que $D(p \,\|\, q) \geq 0$, avec égalité si et seulement si $p = q$.
(b) Calculer $D(p \,\|\, q)$ et $D(q \,\|\, p)$ pour $p = \left(\frac{1}{2}, \frac{1}{2}\right)$ et $q = \left(\frac{1}{4}, \frac{3}{4}\right)$. La divergence est-elle une distance ?
(c) Montrer que minimiser l'entropie croisée $H(p, q)$ en q revient à minimiser $D(p \,\|\, q)$. Pourquoi entraîne-t-on les modèles de langage en minimisant l'entropie croisée ?

VIII. Plongements et attention

Un modèle à n-grammes a deux défauts (partie VII). Il ne regarde que les quelques symboles précédents : pour accorder le verbe de « Le chat que les enfants du voisin poursuivaient dormait », il faut se souvenir de « chat », sept mots plus tôt. Et il apprend chaque contexte séparément : avoir vu « le chat dort » ne lui apprend rien sur « le chien dort ». Les modèles actuels corrigent ces deux défauts par deux idées, que cette partie expose : représenter les mots par des vecteurs, pour que des mots semblables aient des représentations voisines ; et laisser chaque position aller chercher l'information utile dans tout le contexte, avec des poids appris, par un mécanisme appelé *attention*. Empilées, ces deux idées forment l'architecture *Transformer* [114], celle de tous les grands modèles de langage.

Comme dans la partie VI, $\mathbf{R}^d$ est muni du produit scalaire $x \cdot y = \sum_{l=1}^{d} x_l y_l$ et de la norme associée. Les vecteurs sont écrits en ligne, et une matrice à N lignes et d colonnes est vue comme la liste de ses N lignes.

VIII.1 Des mots aux vecteurs

Le texte est d'abord découpé en *symboles* (des mots ou des morceaux de mots), pris dans un vocabulaire de taille V, de l'ordre de 50 000. Le plus simple est de représenter le symbole numéro i par le vecteur e_i de la base canonique de $\mathbf{R}^V$, dont toutes les coordonnées sont nulles sauf la i-ième, égale à 1. Mais pour ces vecteurs, $e_i \cdot e_j = 0$ et $\|e_i - e_j\| = \sqrt{2}$ dès que $i \neq j$: tous les symboles sont à la même distance les uns des autres, et « chat » n'est pas plus proche de « chien » que de « parapluie ».

Définition VIII.1 (Plongement)**.** Un *plongement* du vocabulaire dans $\mathbf{R}^d$ est une matrice $E \in \mathcal{M}_{V,d}(\mathbf{R})$: le symbole i est représenté par la i-ième ligne x_i de E, c'est-à-dire par $e_i E$. La *similarité cosinus* de deux vecteurs non nuls x et y est

$$\cos(x, y) = \frac{x \cdot y}{\|x\| \, \|y\|}.$$

La dimension d (quelques centaines à quelques milliers) est bien plus petite que V. Les coefficients de E sont des paramètres comme les autres, appris par descente de gradient en même temps que le reste du modèle. Pour bien prédire le mot suivant, le modèle a intérêt à donner des vecteurs voisins à des mots qui apparaissent dans des contextes semblables : ce qu'il apprend sur l'un profite alors à l'autre. La similarité cosinus est bien comprise entre -1 et 1, grâce à l'inégalité suivante, qui étend celle du plan (corollaire I.1 du chapitre 4) à toute dimension.

Lemme VIII.1 (Inégalité de Cauchy-Schwarz dans $\mathbf{R}^d$)**.** Pour tous $x, y \in \mathbf{R}^d$, $|x \cdot y| \leq \|x\| \, \|y\|$, avec égalité si et seulement si x et y sont colinéaires.

Preuve. Si $y = 0$, c'est clair. Sinon, pour tout réel t, $\|x + ty\|^2 = \|y\|^2 t^2 + 2(x \cdot y)\, t + \|x\|^2 \geq 0$. Ce trinôme en t garde un signe constant : son discriminant est négatif ou nul, soit $4(x \cdot y)^2 - 4\|x\|^2 \|y\|^2 \leq 0$. Il y a égalité si et seulement si le trinôme a une racine t_0, c'est-à-dire si $x + t_0 y = 0$. ∎

Exemple VIII.1 (Les capitales)**.** En 2013, Mikolov et ses collègues ont appris des plongements de quelques centaines de dimensions sur des milliards de mots de textes d'actualité [80]. Ils ont constaté que des relations entre mots se traduisaient par des vecteurs presque constants : le vecteur $x_{\text{Paris}} - x_{\text{France}}$ est très proche de $x_{\text{Rome}} - x_{\text{Italie}}$, de $x_{\text{Berlin}} - x_{\text{Allemagne}}$, etc. (fig. 6.10). Le mot dont le vecteur est le plus proche, au sens de la similarité cosinus, de $x_{\text{Paris}} - x_{\text{France}} + x_{\text{Italie}}$ est alors, le plus souvent, « Rome ». Personne n'a programmé la notion de capitale : elle est apparue d'elle-même, comme une direction de l'espace, parce qu'elle aide à prédire les mots.

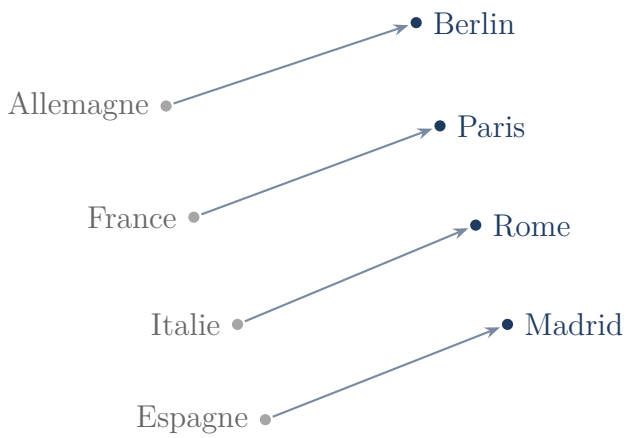


Figure 6.10 Projection en dimension 2 de plongements de pays et de capitales (vecteurs fictifs, dans l'esprit des figures de [80]). Le vecteur qui mène d'un pays à sa capitale est presque le même pour tous les pays : la notion de capitale est devenue une direction de l'espace.

VIII.2 L'attention

Soit un contexte de N symboles, représentés par des vecteurs $x_1, \ldots, x_N$ de $\mathbf{R}^d$. On veut calculer, pour chaque position t, un nouveau vecteur y_t qui rassemble l'information utile des positions $s \leq t$: pour « dormait », celle de « chat » (fig. 6.11). L'idée est celle d'une recherche dans un dictionnaire : chaque position émet une *question*, chaque position précédente présente une *clé*, et l'on récupère les *valeurs* associées aux clés qui répondent le mieux à la question.